

Informe Técnico–Ético: Sistema Centinela CERV-D (Fase 2)

Estudiantes: Jeferson Torrado Bayona – Edwin Yhovany Garzon Amezquita

Programa: Maestría en Ciencia de Datos – Universidad Santo Tomás

Cliente: Dirección de Gestión del Riesgo en Salud (EPS)

1. El problema: hacia una detección multimodal del riesgo de Retinopatía Diabética

La Retinopatía Diabética (RD) continúa siendo una de las principales causas de pérdida irreversible de la visión en población adulta. Su progresión es silenciosa y, en numerosas ocasiones, los pacientes permanecen asintomáticos hasta que el daño vascular en la retina alcanza etapas avanzadas. Esta condición convierte al diagnóstico temprano en un componente esencial dentro de los programas de prevención desarrollados por las Entidades Promotoras de Salud (EPS).

Aunque la revisión clínica realizada por especialistas constituye el estándar de referencia para el diagnóstico, el crecimiento sostenido de la población diabética incrementa la demanda de tamizajes oftalmológicos, generando retrasos en la atención y limitando la capacidad institucional para priorizar oportunamente los pacientes con mayor riesgo.

Durante la primera fase del proyecto Centinela CERV-D se demostró que una Red Neuronal Multicapa (MLP) entrenada sobre variables clínicas estructuradas era capaz de identificar patrones asociados con la enfermedad. Sin embargo, este enfoque presenta una limitación inherente: únicamente analiza información tabular previamente extraída de las imágenes retinianas y no aprovecha directamente la riqueza visual contenida en las fotografías del fondo de ojo.

La segunda fase aborda este desafío mediante una aproximación **multimodal**, integrando dos fuentes complementarias de información:

- **Información clínica estructurada**, representada por variables numéricas derivadas del examen oftalmológico.
- **Información visual**, obtenida directamente de imágenes de retina mediante técnicas de Deep Learning y Transfer Learning.

La hipótesis central del proyecto establece que ambas modalidades contienen información complementaria. Mientras la rama tabular resume características cuantificables previamente calculadas, la rama visual puede descubrir patrones anatómicos complejos que no se encuentran explícitamente representados en dichas variables. La combinación de ambas fuentes busca incrementar la capacidad predictiva del sistema, reducir errores diagnósticos y fortalecer el proceso de priorización clínica dentro de la EPS.

En consecuencia, el objetivo de esta fase consiste en construir un sistema inteligente capaz de integrar evidencia clínica y visual para apoyar la detección temprana de

Retinopatía Diabética, manteniendo un equilibrio entre desempeño predictivo, interpretabilidad y responsabilidad ética.

2. Metodología: arquitectura multimodal del sistema Centinela CERV-D

La metodología implementada corresponde a un enfoque de aprendizaje profundo multimodal, en el cual se entrenan de manera independiente dos modelos especializados que posteriormente son integrados mediante una etapa de fusión para producir una predicción única del riesgo clínico.

La primera rama corresponde al **modelo tabular**, construido sobre un Perceptrón Multicapa (MLP). Este componente recibe como entrada las variables clínicas previamente normalizadas y aprende relaciones no lineales entre las características anatómicas descritas en el conjunto de datos. Esta rama conserva la arquitectura desarrollada durante la Fase 1 y constituye la línea base para evaluar la contribución de las demás modalidades.

La segunda rama implementa un modelo de visión por computador basado en **Transfer Learning**. En lugar de entrenar una red convolucional desde cero, se reutiliza una arquitectura previamente entrenada sobre grandes colecciones de imágenes naturales, permitiendo aprovechar representaciones visuales de alto nivel. Durante el entrenamiento se reemplazan las capas finales por un clasificador específico para la detección de Retinopatía Diabética y se realiza un proceso de ajuste fino (*fine tuning*) sobre las últimas capas de la red.

Las imágenes fueron sometidas a un proceso de preprocesamiento que incluye redimensionamiento, normalización y técnicas de aumento de datos (*data augmentation*), con el propósito de incrementar la capacidad de generalización del modelo frente a variaciones de iluminación, orientación y características propias de las imágenes clínicas.

Finalmente, ambas ramas convergen en un esquema de **fusión multimodal**, donde las representaciones latentes generadas por el modelo tabular y la CNN son combinadas para producir una única predicción de riesgo. Esta estrategia permite aprovechar simultáneamente la información clínica estructurada y la evidencia visual, incrementando la robustez del sistema frente a casos complejos.

El entrenamiento de los modelos se realizó utilizando funciones de pérdida apropiadas para clasificación binaria, optimización mediante Adam y estrategias de validación orientadas a minimizar el sobreajuste observado durante las primeras etapas del desarrollo.




Figura 1. Arquitectura general del sistema multimodal Centinela CERV-D.

3. Resultados: evaluación comparativa de las tres ramas del modelo

La evaluación experimental se diseñó para analizar el aporte individual de cada modalidad y cuantificar el beneficio obtenido mediante la integración multimodal. Para ello se evaluaron tres configuraciones independientes:

- **Rama tabular (MLP):** utiliza únicamente variables clínicas estructuradas.
- **Rama visual (CNN con Transfer Learning):** emplea exclusivamente imágenes del fondo de ojo.
- **Modelo multimodal:** combina simultáneamente ambas fuentes de información.

El desempeño de cada configuración fue medido mediante métricas estándar para problemas de clasificación binaria, incluyendo exactitud (*Accuracy*), precisión (*Precision*), sensibilidad (*Recall*), puntuación F1 y análisis mediante matriz de confusión. Adicionalmente, se analizaron las curvas de entrenamiento y validación para verificar la estabilidad del proceso de aprendizaje y detectar posibles fenómenos de sobreajuste.

Los resultados obtenidos evidencian que las dos modalidades capturan información complementaria. Mientras la rama tabular presenta un comportamiento consistente al modelar relaciones clínicas previamente cuantificadas, la rama visual identifica patrones morfológicos directamente sobre las imágenes retinianas. La estrategia de fusión logra integrar ambas representaciones, obteniendo un desempeño superior respecto a las modalidades individuales y reduciendo la probabilidad de errores de clasificación en escenarios clínicos complejos.




Figura. Rama A completa: arquitecturas comparadas, FE/FT/completo entrenados y evaluados, Grad-CAM

Además de las métricas globales, el notebook incorpora matrices de confusión y ejemplos de clasificación que permiten analizar el comportamiento del modelo frente a verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos. Este análisis resulta especialmente relevante desde la perspectiva clínica, dado que los falsos negativos representan pacientes que podrían evolucionar hacia pérdida irreversible de la visión sin recibir atención oportuna.




Figura. Comparación de desempeño entre la rama tabular, la rama visual y el modelo multimodal.

El estudio de ablación evidencia que la eliminación de cualquiera de las dos modalidades disminuye el desempeño global del sistema, confirmando que ambas aportan información complementaria para el diagnóstico asistido por inteligencia artificial.

4. Estudio de ablación

Con el propósito de cuantificar la contribución individual de cada modalidad de información, se realizó un estudio de ablación comparando el desempeño de tres

configuraciones del sistema Centinela CERV-D: la rama tabular, la rama visual basada en Transfer Learning y el modelo multimodal que integra ambas fuentes de información. Este análisis permite determinar el impacto que tiene cada componente sobre la capacidad predictiva del sistema y justificar la arquitectura final seleccionada.

La primera configuración corresponde a la **rama tabular**, construida mediante un Perceptrón Multicapa (MLP), cuyo entrenamiento utiliza exclusivamente variables clínicas estructuradas derivadas de los exámenes oftalmológicos. Esta configuración constituye la línea base del proyecto y permite evaluar la capacidad del modelo para identificar patrones clínicos sin incorporar información visual.

La segunda configuración corresponde a la **rama visual**, implementada mediante una Red Neuronal Convolutiva entrenada con Transfer Learning. En este caso, el modelo recibe únicamente imágenes del fondo de ojo y aprende automáticamente representaciones anatómicas relevantes para la clasificación de la Retinopatía Diabética. La reutilización de pesos preentrenados permitió acelerar la convergencia y mejorar la capacidad de generalización del modelo respecto a un entrenamiento desde cero.

Finalmente, la tercera configuración corresponde al **modelo multimodal**, donde las representaciones aprendidas por ambas ramas son fusionadas antes de la capa de clasificación. Esta estrategia permite combinar información clínica estructurada con características visuales de alto nivel, aprovechando la complementariedad existente entre ambas modalidades.

Los resultados experimentales obtenidos muestran que la arquitectura multimodal alcanza el mejor equilibrio entre sensibilidad y precisión, al incorporar simultáneamente evidencia clínica y visual. En comparación con las modalidades individuales, la estrategia de fusión reduce los errores de clasificación en pacientes con patrones difíciles de identificar mediante una única fuente de información.




Figura. Comparación de desempeño entre la rama tabular, la rama visual y el modelo multimodal.

El estudio de ablación evidencia que la eliminación de cualquiera de las dos modalidades disminuye el desempeño global del sistema, confirmando que ambas aportan información complementaria para el diagnóstico asistido por inteligencia artificial.

5. Limitaciones de las tres ramas

Aunque los resultados obtenidos demuestran la viabilidad del enfoque multimodal, cada una de las ramas presenta limitaciones que deben considerarse antes de una posible implementación en un entorno clínico.

5.1 Rama tabular

El modelo tabular depende completamente de la calidad de las variables clínicas previamente extraídas. Cualquier error durante el proceso de medición o segmentación de características anatómicas afecta directamente el desempeño del clasificador. Además, esta modalidad no tiene acceso a la información visual completa de la retina, por lo que puede omitir patrones morfológicos complejos que no estén representados en las variables estructuradas.

5.2 Rama visual

La rama basada en Transfer Learning requiere un conjunto representativo de imágenes correctamente etiquetadas para obtener un adecuado proceso de generalización. Variaciones en iluminación, resolución, calidad de captura o presencia de artefactos pueden afectar el desempeño del modelo. Asimismo, la naturaleza profunda de las redes convolucionales reduce la interpretabilidad del proceso de decisión, lo cual constituye un desafío para aplicaciones clínicas.

5.3 Modelo multimodal

Aunque la fusión multimodal mejora el desempeño predictivo, incrementa significativamente la complejidad computacional del sistema. La necesidad de procesar simultáneamente información tabular e imágenes implica mayores tiempos de entrenamiento e inferencia, así como una mayor demanda de recursos de hardware.

Adicionalmente, el modelo requiere que ambas modalidades estén disponibles para realizar la predicción. La ausencia de una de las fuentes de información puede limitar la aplicabilidad del sistema en escenarios reales.

6. Análisis técnico–ético

La incorporación de inteligencia artificial en procesos de apoyo al diagnóstico médico exige evaluar no solamente el desempeño predictivo, sino también los aspectos éticos asociados a su utilización.

Uno de los principales riesgos corresponde a los **falsos negativos**, es decir, pacientes diagnosticados erróneamente como sanos cuando en realidad presentan Retinopatía Diabética. Desde la perspectiva clínica, este tipo de error puede retrasar el tratamiento

oportuno y favorecer la progresión irreversible de la enfermedad. Por esta razón, la calibración del umbral de decisión debe priorizar la sensibilidad del sistema frente a la reducción de falsos positivos.

Otro aspecto relevante corresponde al posible **sesgo del conjunto de datos**. Si las imágenes utilizadas para el entrenamiento no representan adecuadamente la diversidad demográfica de la población objetivo, el modelo puede presentar un desempeño desigual entre diferentes grupos de pacientes. Esto hace indispensable realizar procesos periódicos de validación externa y actualización del modelo.

Asimismo, las redes neuronales profundas presentan limitaciones de interpretabilidad. Aunque proporcionan elevados niveles de desempeño, el proceso interno mediante el cual generan una predicción no resulta fácilmente explicable para el personal médico. Por esta razón, el sistema Centinela CERV-D debe considerarse un mecanismo de apoyo a la decisión clínica y no un reemplazo del criterio del especialista.

La protección de la información clínica constituye otro componente fundamental. Las imágenes retinianas y las variables médicas utilizadas durante el entrenamiento contienen información sensible y deben ser administradas bajo principios de confidencialidad, anonimización y cumplimiento de la normativa vigente sobre protección de datos personales.

Finalmente, desde la perspectiva de gobernanza de inteligencia artificial, se recomienda establecer procesos continuos de monitoreo del desempeño del modelo, auditorías periódicas de sus resultados y mecanismos de actualización conforme se disponga de nuevos datos clínicos.

7. Conclusiones

La segunda fase del proyecto Centinela CERV-D permitió demostrar la viabilidad de un enfoque multimodal para la detección temprana de Retinopatía Diabética, integrando información clínica estructurada con imágenes del fondo de ojo mediante técnicas de Transfer Learning.

El estudio de ablación evidenció que ambas modalidades aportan información complementaria y que la estrategia de fusión mejora el desempeño global respecto a los modelos individuales. Este resultado confirma la hipótesis de que la integración de diferentes fuentes de información incrementa la capacidad predictiva del sistema y reduce la probabilidad de errores diagnósticos.

Desde la perspectiva técnica, el empleo de redes convolucionales preentrenadas permitió aprovechar representaciones visuales robustas, reduciendo los tiempos de entrenamiento y favoreciendo la generalización del modelo. La incorporación de la rama tabular complementó dicho aprendizaje mediante variables clínicas previamente validadas por especialistas.

No obstante, el sistema presenta limitaciones relacionadas con la disponibilidad de datos, el tamaño del conjunto de entrenamiento, la interpretabilidad de las redes neuronales profundas y la necesidad de recursos computacionales para el

procesamiento multimodal. Estas restricciones deberán ser consideradas en futuras etapas del proyecto.

8. Referencias

Antal, B., & Hajdu, A. (2014). *An ensemble-based system for automatic screening of diabetic retinopathy*. *Knowledge-Based Systems*, 60, 20–27.

Diabetic Retinopathy Debrecen Data Set. (2014). *UCI Machine Learning Repository*. <https://doi.org/10.24432/C5V89Q>

He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep residual learning for image recognition*. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition.

Howard, A. G., et al. (2019). *Searching for MobileNetV3*. Proceedings of the IEEE International Conference on Computer Vision.

Paszke, A., et al. (2019). *PyTorch: An imperative style, high-performance deep learning library*. Advances in Neural Information Processing Systems, 32.

Shorten, C., & Khoshgoftaar, T. M. (2019). *A survey on image data augmentation for deep learning*. Journal of Big Data, 6(60).