

Informe Técnico-Ético: Sistema Centinela CERV-D (Fase 1)

Estudiantes: Jeferson Torrado Bayona - Edwin Yhovany Garzon Amezquita

Programa: Maestría en Ciencia de Datos, Universidad Santo Tomás

Cliente: Dirección de Gestión del Riesgo en Salud (EPS)

1. El Problema: El riesgo oculto de la Retinopatía Diabética

La Retinopatía Diabética (RD) es una complicación silenciosa que, de no detectarse a tiempo, conduce a la ceguera irreversible. Actualmente, el tamizaje oftalmológico depende de una revisión manual exhaustiva, lo que genera cuellos de botella en la atención, retrasos en el diagnóstico y, en el peor de los casos, la omisión de pacientes que ya presentan daños microscópicos (como microaneurismas o fugas de lípidos) imposibles de detectar a simple vista. El desafío para la EPS no es solo médico, sino operativo: ¿cómo identificamos rápidamente a los pacientes en riesgo crítico antes de que pierdan la visión, optimizando los recursos oftalmológicos disponibles?

2. El Modelo: Sistema Centinela como copiloto diagnóstico

Para resolver este desafío, desarrollamos el sistema CERV-D (Centinela de Evaluación de Riesgo Visual por Diabetes). En lugar de reemplazar al especialista, el sistema actúa como un "radar de alerta temprana".

Utilizamos una arquitectura de Inteligencia Artificial (Red Neuronal Artificial) entrenada con datos históricos validados (Diabetic Retinopathy Debrecen Data Set). El sistema evalúa 19 características anatómicas del ojo del paciente (como el área de exudados y la distancia al nervio óptico) y busca patrones complejos que indican la presencia de la enfermedad. El modelo procesa esta información y emite una calificación de riesgo, permitiendo a la EPS priorizar las citas de los pacientes que realmente necesitan intervención inmediata.




Figura 1: Flujo de información clínica en el modelo CERV-D

2.1. Diseño de la Arquitectura Neuronal Base

El núcleo predictivo del sistema fue construido desde cero utilizando un Perceptrón Multicapa (MLP) sobre el entorno de desarrollo PyTorch. Para procesar la complejidad de la anatomía ocular, diseñamos una arquitectura de extracción progresiva:

- Capa de Entrada (19 nodos): Recibe las mediciones anatómicas en bruto.
- Capas Ocultas (32 y 16 neuronas): Constituyen el motor de razonamiento. Inyectamos funciones de activación no lineales (ReLU) entre estas capas, lo que permite al modelo comprender relaciones anatómicas complejas.
- Capa de Salida (1 nodo): Retorna un valor numérico crudo (*logit*) sin activación final para garantizar la máxima estabilidad matemática en el cálculo del riesgo.

2.2. Pruebas de Estrés: El Problema de la Memorización (Sobreajuste)

Un modelo de Inteligencia Artificial en salud debe ser capaz de generalizar, no de memorizar. Para auditar esta capacidad, sometimos al sistema a una prueba de estrés: redujimos deliberadamente el conjunto de datos de entrenamiento a solo un tercio de los pacientes disponibles y expusimos el modelo a un entrenamiento intensivo.

El resultado evidenció un riesgo algorítmico crítico conocido como Sobreajuste (Overfitting), Figura 3. Al tener tan pocos ejemplos y demasiada capacidad matemática, la red neuronal optó por el camino fácil: se aprendió de memoria los historiales exactos de ese tercio de pacientes. Las métricas de error interno bajaron a cero, creando la falsa ilusión de un modelo perfecto. Sin embargo, al presentarle pacientes nuevos (datos de validación), el sistema falló considerablemente. Si este modelo base se hubiera desplegado en la EPS, habría sido incapaz de diagnosticar a los nuevos afiliados.




Figura 3. Prueba de estrés algorítmico (Sobreajuste Inducido)

2.3. Estabilización mediante Regularización (Dropout)

Para neutralizar esta vulnerabilidad y forzar al modelo a aprender de la patología (Retinopatía Diabética), intervenimos el código de la arquitectura implementando una técnica avanzada de regularización conocida como Dropout.

Configuramos una capa de `nn.Dropout(p=0.5)`, la cual tiene un efecto drástico y deliberado: durante cada ciclo de aprendizaje, "apaga" aleatoriamente el 50% de las neuronas de la red. Al no poder depender siempre de las mismas rutas matemáticas, obligamos a todas las neuronas a trabajar en equipo y a extraer características redundantes y robustas.

Esta intervención arregló el sobreajuste. Las curvas de aprendizaje de entrenamiento y validación se alinearon (ver Figura 4), demostrando que el modelo final de CERV-D no memoriza expedientes pasados, sino que posee una verdadera capacidad predictiva para auditar historiales médicos inéditos.




Figura 4. Figura 3: Estabilización del aprendizaje mediante Regularización (Dropout al 50%)

2.4. El Motor de Aprendizaje: Optimización y Función de Pérdida

Una vez diseñada la arquitectura neuronal, el sistema requiere un motor matemático que le enseñe a diferenciar entre un paciente sano y uno en riesgo. Este proceso (el bucle de entrenamiento) se configuró operando bajo tres componentes técnicos fundamentales:

1. La Brújula del Error (Función de Pérdida): Seleccionamos la Entropía Cruzada Binaria con Logits (BCEWithLogitsLoss). En términos clínicos, esta función penaliza matemáticamente al modelo cada vez que su predicción se aleja del diagnóstico real del oftalmólogo. Al integrar el cálculo de probabilidad directamente en la pérdida, evitamos inestabilidades numéricas.
2. El Motor de Ajuste (Optimizador): Implementamos el algoritmo Adam (Adaptive Moment Estimation). A diferencia de métodos tradicionales, Adam ajusta dinámicamente cómo aprende la red basándose en el historial de errores.
3. El Ritmo de Adaptación (Tasa de Aprendizaje): Configuramos el Learning Rate en 0.001. Esta "velocidad de aprendizaje" garantiza que el modelo haga ajustes milimétricos en sus parámetros tras analizar a cada paciente, evitando saltos bruscos que desestabilizarían el diagnóstico.

La mecánica del entrenamiento: Durante 150 ciclos completos (épocas), el sistema iteró sobre todo el historial médico mediante un bucle explícito de cinco pasos continuos:

- Emitir un pre-diagnóstico (Forward Pass).
- Medir la gravedad del error frente al diagnóstico real (Loss).
- Calcular qué reglas anatómicas causaron la falla (Backward Pass).
- Ajustar los parámetros internos para no repetir el error (Optimizer Step).
- Limpiar la memoria para evaluar al siguiente paciente. Este ciclo continuo garantizó que el modelo pasara de realizar predicciones aleatorias en la primera época, a converger en un sistema de alerta altamente especializado.

3. El Error: La anatomía de las fallas y el dilema ético

Como cualquier sistema predictivo, CERV-D no es infalible. Durante las pruebas de auditoría, analizamos cómo se equivoca el modelo bajo una configuración estándar (confianza matemática del 50%) y cómo mejora al disminuir los umbrales para la predicción. Observamos dos tipos de errores:

- **Falsas Alarmas (Falsos Positivos):** El sistema alerta sobre un paciente sano. El costo operativo es una cita oftalmológica innecesaria.
- **Riesgos Omitidos (Falsos Negativos):** El sistema clasifica como "sano" a un paciente que sí tiene retinopatía. El costo clínico es gravísimo: la posible ceguera del afiliado.

En nuestro primer escenario (Mecánico), el modelo omitía un número inaceptable de casos reales de riesgo. La Inteligencia Artificial, si se deja bajo criterios puramente matemáticos, prioriza la exactitud global sin comprender el daño humano que causa un falso negativo.




Figura 5. Impacto del umbral de decisión en la priorización del riesgo clínico.

4. La Decisión: Gobernanza clínica y ajuste preventivo

Ante este dilema ético, la decisión estratégica fue intervenir la configuración del modelo, priorizando la ética médica sobre la estética estadística.

Hemos calibrado el umbral de decisión del sistema al **0.2 (Escenario Ultra-Preventivo)**. Esto significa que si el modelo detecta tan solo un 20% de probabilidad de riesgo en los patrones visuales, activará la alerta.

- **El resultado clínico:** Logramos capturar al 84% de los pacientes en riesgo real (Sensibilidad del 0.84), reduciendo drásticamente las omisiones fatales.
- **El compromiso operativo:** Aceptamos conscientemente un aumento en las falsas alarmas (Precisión del 0.65).

Recomendación a la Dirección: Se recomienda la adopción del sistema CERV-D bajo el umbral 0.2. La EPS asume el costo administrativo de realizar tamizajes preventivos adicionales a pacientes sanos, garantizando a cambio una política de "cero tolerancia" frente a la pérdida de visión de nuestros afiliados.

Referencias

- Antal, B., & Hajdu, A. (2014). An ensemble-based system for automatic screening of diabetic retinopathy. *Knowledge-Based Systems*, 60, 20-27.
- Diabetic Retinopathy Debrecen Data Set. (2014). UCI Machine Learning Repository. <https://doi.org/10.24432/C5V89Q>.
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... & Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in neural information processing systems*, 32.